

DOCUMENTATION DE PROJET

Financial Analytics — Fabric + Power BI

Guide complet du projet : contexte métier, vocabulaire, architecture, étapes réalisées, scripts et décisions techniques, analyses et enseignements. Rédigé pour que chaque choix — technique comme métier — soit compris, pas seulement exécuté.

Projet personnel · Ingestion ERP/Excel/SQL → OneLake → Lakehouse → Warehouse → Power BI
Stack : Microsoft Fabric, Azure, PySpark, SQL, DAX, Power BI

01 Contexte et objectifs

Pourquoi ce projet existe et quel problème métier il résout.

Dans une entreprise multi-entités (plusieurs pays/filiales), les données financières arrivent généralement de **trois sources différentes** : un ERP (système de gestion comptable), des fichiers **Excel de budget** maintenus par les contrôleurs de gestion, et parfois une base **SQL Server** annexe. Ces sources sont rarement parfaitement alignées : décalages de nomenclature, doublons, valeurs manquantes, retards de livraison. Le rôle d'une plateforme de *Financial Analytics* est de consolider ces sources dans un modèle unique, fiable et gouverné, pour produire des tableaux de bord de pilotage (budget vs réalisé, rentabilité, prévisions).

Ce projet reproduit ce scénario de bout en bout : de la génération d'un jeu de données réaliste (avec anomalies volontaires) jusqu'aux tableaux de bord Power BI, en passant par l'ingestion, le contrôle qualité, la modélisation et la sécurité des données.

Objectif du projet : démontrer la maîtrise d'une chaîne complète Fabric + Power BI — ingestion, gouvernance de la donnée (Data Quality), modélisation dimensionnelle, DAX, sécurité (RLS) — sur un cas d'usage financier réaliste.

02 Glossaire métier — Finance

Les termes utilisés dans les mesures et les rapports, expliqués simplement.

TERME	DÉFINITION
Actual	Le réalisé : ce qui s'est effectivement passé (dépenses et revenus réellement enregistrés dans l'ERP).
Budget	Le prévisionnel validé en début de période par la direction financière — la cible à laquelle on compare le réalisé.
Forecast	Une réestimation du budget en cours d'année, à partir des tendances observées (plus récente et réaliste que le Budget initial).
Variance	L'écart en valeur absolue entre Actual et Budget (Actual – Budget). Négatif = moins bien que prévu (si c'est du revenu) ou mieux que prévu (si c'est une dépense).
Variance %	Le même écart, exprimé en pourcentage du Budget — permet de comparer des montants de tailles très différentes.
YoY (Year over Year)	Comparaison à la même période l'année précédente. Mesure la croissance réelle, indépendamment des effets saisonniers.
MoM (Month over Month)	Comparaison au mois précédent. Plus réactif que le YoY, mais plus sensible aux variations saisonnières.
YTD (Year To Date)	Cumul depuis le 1er janvier de l'année en cours jusqu'à la période sélectionnée.
Revenue	Le chiffre d'affaires — tout ce que l'entreprise facture à ses clients.
COGS (Cost of Goods Sold)	Le coût direct de production des biens/services vendus (matières premières, fabrication).
Opex (Operating Expenses)	Les charges d'exploitation courantes : salaires, marketing, loyers, informatique — tout ce qui fait tourner l'entreprise au quotidien.
D&A (Depreciation & Amortization)	La dépréciation comptable des actifs (matériel, logiciels) répartie sur plusieurs années — une charge non monétaire (pas de sortie de trésorerie réelle sur la période).
EBITDA	Revenue – COGS – Opex. La rentabilité opérationnelle avant intérêts, impôts, D&A — l'indicateur clé pour juger la performance d'une activité indépendamment de sa structure financière.
Marge EBITDA %	$EBITDA \div Revenue$. Le pourcentage du chiffre d'affaires qui se transforme en rentabilité opérationnelle.
Centre de coûts (Cost Center)	Une unité organisationnelle (Sales, Marketing, IT...) à laquelle on rattache des dépenses pour suivre qui dépense quoi.
Entité (Entity)	Une filiale ou zone géographique de l'entreprise (ex. France, Germany, USA) — le niveau auquel on consolide et sécurise l'accès aux données (RLS).
Grand livre (General Ledger / GL)	Le registre comptable de toutes les transactions financières de l'entreprise, organisé par compte.

**Compte (Account /
Chart of Accounts)**

La ligne budgétaire précise (ex. "Marketing Spend", "Salaries & Wages") — le niveau de détail le plus fin du P&L.

**P&L (Profit & Loss /
compte de résultat)**

Le document qui récapitule Revenue, charges et résultat net sur une période.

03 Glossaire technique — Data & Cloud

Le vocabulaire Fabric/Azure rencontré pendant le projet.

TERME	DÉFINITION
Tenant	L'espace Microsoft 365/Azure qui isole les données et utilisateurs d'une organisation. Chaque compte professionnel appartient à un tenant, identifié par un domaine <code>*.onmicrosoft.com</code> .
Microsoft Entra ID (ex-Azure AD)	Le service d'identité et d'accès du tenant : c'est là que sont créés les comptes utilisateurs, les rôles d'administration, les groupes de sécurité.
Compte professionnel/scolaire vs personnel	Un compte "personnel" (Gmail, Outlook.com) est un compte Microsoft individuel (MSA). Un compte "professionnel" appartient à un tenant Entra ID. Fabric exige un compte professionnel pour se connecter — c'est la raison de la création d'un tenant dédié dans ce projet.
RBAC (Role-Based Access Control)	Le système d'attribution de rôles (Lecteur, Contributeur, Propriétaire...) qui détermine ce qu'un compte a le droit de faire sur une ressource Azure.
Resource Provider	Le "service" Azure qui doit être activé sur un abonnement avant de pouvoir créer un type de ressource donné (ex. <code>Microsoft.Fabric</code> pour créer une capacité Fabric).
Capacité Fabric	La puissance de calcul réservée qui permet à un workspace d'utiliser les fonctionnalités avancées de Fabric (Lakehouse, Warehouse, notebooks). Facturée à l'usage (ex. F2 ≈ 0,36 \$/h), peut être mise en pause.
Workspace	Le dossier de travail Fabric/Power BI qui regroupe les items d'un projet (Lakehouse, Warehouse, rapports, modèles).
OneLake	Le stockage unifié de tout le tenant Fabric — un seul "lac de données" partagé par tous les workspaces, sur lequel s'appuient Lakehouse et Warehouse.
Lakehouse	Un espace de stockage combinant fichiers bruts (dossier <code>Files</code>) et tables structurées interrogeables en SQL (dossier <code>Tables</code> , format Delta).
Warehouse	Une base de données relationnelle managée (SQL pur), utilisée ici pour la couche Gold — le modèle final en étoile.
Notebook / PySpark	Un environnement de code (cellules Python/SQL exécutées sur un cluster Spark) utilisé pour transformer et nettoyer des données à grande échelle.
Table Delta	Le format de table utilisé par Lakehouse/Warehouse — un format de fichier structuré avec historique des versions, contrairement à un simple CSV.
Architecture en médaillon (Bronze/Silver/Gold)	Une convention de nommage des couches de données : Bronze = brut tel que reçu, Silver = nettoyé et validé, Gold = modélisé et prêt pour l'analyse.
Schéma en étoile (Star Schema)	Un modèle de données avec une table de faits (les transactions) reliée à plusieurs tables de dimensions (Date, Compte, Entité...) — le standard pour la modélisation décisionnelle.

**Modèle sémantique
(Semantic Model)**

Le modèle Power BI qui définit les tables, relations et mesures DAX — la couche entre les données et les visuels.

**DAX (Data Analysis
Expressions)**

Le langage de formules utilisé pour écrire les mesures Power BI (ex. calculer une somme filtrée, une variation d'une période à l'autre).

Direct Lake


Le mode de connexion Power BI qui lit directement les tables Delta d'un Lakehouse/Warehouse sans dupliquer les données (ni Import, ni DirectQuery classique) — rapide et toujours à jour.

RLS (Row-Level Security)

Un mécanisme qui restreint les lignes visibles dans un rapport selon l'utilisateur connecté (ex. un utilisateur "France" ne voit que les données de l'entité France).

04 Architecture du projet

Le chemin complet parcouru par la donnée, de la source au dashboard.



Chaque flèche correspond à un item Fabric distinct, volontairement séparé : cela permet de retraiter une couche sans toucher aux autres (ex. relancer le nettoyage Silver sans reconstruire le Warehouse), et reflète l'organisation réelle d'une équipe data (ingénierie de données en amont, modélisation et BI en aval).

05 Étapes réalisées

Chronologie du projet : ce qui a été fait, pourquoi, et avec quels outils.

5.1 — Mise en place de l'environnement cloud

Azure · Entra ID · Fabric

Le compte disponible était un ancien compte étudiant sans accès administrateur — impossible d'activer un essai Fabric dessus (le trial Fabric est bloqué sur certains tenants, notamment les tenants récents ou sans droits d'administration). La solution retenue :

1. Création d'un **compte Azure gratuit** avec un email personnel → génère automatiquement un nouveau tenant Microsoft Entra ID, avec 200 \$ de crédit gratuit (30 jours).
2. Création d'un **utilisateur professionnel** dans ce tenant (admin@tenant.onmicrosoft.com) avec le rôle *Administrateur général* — car Fabric refuse toute connexion avec un compte personnel (MSA), même propriétaire de l'abonnement.
3. Attribution du rôle **Contributeur** à ce compte sur l'abonnement Azure (RBAC), pour qu'il puisse créer des ressources.
4. Enregistrement du **Resource Provider** Microsoft.Fabric sur l'abonnement — sans cette étape, la ressource "capacité Fabric" n'apparaît nulle part dans le portail.
5. Création d'une **capacité Fabric F2** (la plus petite taille, ≈ 0,36 \$/h), payée par le crédit gratuit — donc gratuite en pratique tant qu'elle est mise en pause hors utilisation.
6. Création du workspace FIN-Dev, assigné à cette capacité.

Pourquoi c'est important à comprendre : ces étapes ne sont pas propres à ce projet — c'est le chemin standard pour tout développeur qui veut utiliser Fabric sans disposer d'un tenant d'entreprise. Le réflexe à retenir : Fabric = compte professionnel + capacité active, toujours.

5.2 — Génération du jeu de données

Python · scripts/generate_dataset.py

Un jeu de données synthétique a été généré plutôt que d'utiliser des données réelles, pour pouvoir travailler immédiatement sans dépendre d'un ERP existant, tout en contrôlant précisément les anomalies à détecter dans la phase Data Quality.

Structure générée (schéma en étoile, 5 entités × 8 centres de coûts × 16 comptes × 31 mois) :

FICHIER	CONTENU
dim_date.csv	Calendrier mensuel (2024-01 à 2026-12)
dim_entity.csv	5 entités : France, Germany, Spain, USA, Japan
dim_costcenter.csv	8 centres de coûts : Sales, Marketing, R&D, Production, IT, HR, Finance, Supply Chain
dim_account.csv	16 comptes du plan comptable, classés en 5 catégories (Revenue, COGS, Opex, D&A, BelowEBITDA)
dim_scenario.csv	3 scénarios : Actual, Budget, Forecast
erp_transactions_raw.csv	Transactions Actual, avec anomalies volontaires (source ERP simulée)

Anomalies injectées volontairement (pour être détectées ensuite par le contrôle Data Quality) : doublons de transactions, valeurs manquantes, montants négatifs invalides sur des comptes de revenu, dates mal formatées, identifiants d'entité ou de compte inconnus du référentiel, libellés d'entité incohérents entre systèmes, combinaisons entité × mois manquantes dans le budget.

Correction apportée en cours de projet : la première version du générateur dupliquait certains comptes de charges (notamment les salaires) dans les 8 centres de coûts à taux plein, alors que le revenu n'était généré que dans un seul centre de coûts. Résultat : un EBITDA fortement négatif (irréaliste). Le générateur a été corrigé pour répartir les montants selon le nombre réel de centres de coûts utilisant chaque compte, donnant un P&L réaliste (Opex ≈ 25% du Revenu, EBITDA positif). Voir section 6 pour le détail de cette analyse.

5.3 — Ingestion Bronze

Lakehouse • Files

Les fichiers `raw_sources` et `reference` ont été chargés tels quels dans le Lakehouse `FIN_Bronze` (dossier `Files`), sans aucune transformation — c'est le principe de la couche Bronze : conserver une copie fidèle de la source, pour pouvoir toujours revenir en arrière si un traitement en aval s'avère incorrect.

5.4 — Contrôles Data Quality

Notebook PySpark • `dq_checks.ipynb`

Un notebook Spark calcule automatiquement un score sur les 6 dimensions de qualité de données retenues pour ce projet, isole les lignes invalides dans des tables de quarantaine, puis produit des tables Silver propres.

DIMENSION	CE QU'ELLE MESURE	RÉSULTAT MESURÉ
Completeness	Valeurs NULL sur les colonnes obligatoires	98,0%
Uniqueness	Transactions dupliquées	99,0%
Validity	Montants négatifs invalides, dates malformées	99,3%
Referential Integrity	Identifiants (entité, compte) absents du référentiel	99,0%
Consistency	Libellés d'entité incohérents entre systèmes	94,8%
Freshness	Combinaisons entité × mois manquantes	93,3%

Score de qualité global : 97,5%, calculé sur 4 070 lignes ERP et 4 368 lignes Budget.




Fig. 1 — Rapport Data Quality (Power BI)

Un second notebook (`load_forecast.ipynb`) charge les lignes de scénario Forecast, considérées comme déjà propres (issues d'un outil FP&A distinct de l'ERP, donc non soumises aux mêmes contrôles).

5.5 — Modélisation Warehouse (Gold) SQL · `build_star_schema.sql`

Un script SQL construit le **schéma en étoile** final dans le Warehouse FIN_Warehouse : 5 tables de dimensions copiées depuis le Lakehouse, et une table de faits Fact_Transactions qui réunit Actual + Budget + Forecast dans un grain unique (1 ligne = 1 mouvement, quel que soit le scénario). Des clés étrangères NOT ENFORCED sont posées pour que Power BI détecte automatiquement les relations.

```
CREATE TABLE dbo.Fact_Transactions (
    transaction_id BIGINT, [date] DATE, entity_id VARCHAR(10),
    cost_center_id VARCHAR(10), account_id VARCHAR(10),
    scenario_id INT, amount DECIMAL(18,2)
);

INSERT INTO dbo.Fact_Transactions
SELECT ... FROM [FIN_Bronze].[dbo].[fact_transactions_silver] -- Actual
UNION ALL
SELECT ... FROM [FIN_Bronze].[dbo].[budget_silver] -- Budget
UNION ALL
SELECT ... FROM [FIN_Bronze].[dbo].[forecast_silver]; -- Forecast
```

Point technique notable : une requête SQL dans un Warehouse Fabric peut interroger directement les tables d'un Lakehouse du même workspace via son nom (`[FIN_Bronze].[dbo].[table]`), sans étape de copie manuelle — c'est la *requête cross-item*.

5.6 — Modèle sémantique et mesures DAX FIN_Model · DAX

Le modèle sémantique FIN_Model relie la table de faits aux 5 dimensions, avec Dim_Date marquée comme table de dates (indispensable pour les fonctions d'intelligence temporelle DAX comme SAMEPERIODYLASTYEAR).

MESURE	RÔLE
Actual / Budget / Forecast	Somme filtrée par scénario
Variance / Variance %	Écart Actual – Budget, en valeur et en %
Actual PY / YoY %	Comparaison à l'année précédente
Actual PM / MoM %	Comparaison au mois précédent
Actual YTD / Budget YTD	Cumuls depuis le 1er janvier
Revenue / COGS / Opex	Sommes filtrées par catégorie de compte
EBITDA / Marge EBITDA %	Rentabilité opérationnelle
Opex Ecart-type 12M	Détection d'anomalies sur les 12 derniers mois de charges

```
EBITDA = [Revenue] - [COGS] - [Opex]
Marge EBITDA % = DIVIDE([EBITDA], [Revenue])
YoY % = DIVIDE([Actual] - [Actual PY], [Actual PY])
```

5.7 — Sécurité : Row-Level Security RLS

Un rôle RLS_France a été créé dans FIN_Model, avec un filtre DAX sur la dimension entité : [entity_name] = "France". Testé via la fonctionnalité "Afficher en tant que" (View as), qui simule la connexion d'un utilisateur assigné à ce rôle sans avoir besoin d'un second compte réel.

5.8 — Rapports Power BI Performance Financière • Data Quality

Rapport "Performance Financière" (3 pages)




Fig. 2 – Page 1 : Vue d'ensemble (KPI, Actual vs Budget, variance par centre de coûts, détail comptes)




Fig. 3 – Page 2 : Détail par entité (matrice hiérarchique, croissance YoY/MoM)




Fig. 4 – Page 3 : EBITDA et rentabilité (Revenue → EBITDA, marge par mois)

06 Analyses et enseignements clés

Ce que l'exploration des données a révélé — et comment ça a été corrigé.

Anomalie n°1 — EBITDA négatif (-26,7 M€, marge -250%)

À la première génération de données, le rapport affichait un EBITDA très négatif. L'analyse des totaux par catégorie de compte a montré que les **Opex représentaient 60% du volume total** contre seulement 21% pour le Revenue — un ratio impossible pour une entreprise saine (la norme est plutôt 20-25% d'Opex sur le CA). Cause racine : le compte "Salaries" était posté dans les 8 centres de coûts à taux plein dans le générateur, alors que le Revenue n'était généré que dans un seul centre de coûts (Sales). **Correction** : les montants de base ont été redéfinis comme des montants "par centre de coûts" déjà répartis selon le nombre réel d'utilisateurs du compte. Résultat après correction : Opex $\approx$ 25% du Revenue, EBITDA de +5,02 M€, marge de 13,8%.

Anomalie n°2 — Variance % anormalement élevée (-13,7%)

Même après la correction n°1, l'écart Actual vs Budget restait trop important. Analyse des dates couvertes par chaque scénario : l'**Actual s'arrêtait à juillet 2026** (31 mois, dernier mois clôturé) alors que le **Budget couvrait toute l'année jusqu'à décembre 2026** (36 mois). Le rapport comparait donc un Actual partiel à un Budget complet, gonflant artificiellement l'écart négatif. **Correction** : le Budget a été recalculé sur la même période que l'Actual (période "alignée") avant comparaison — pratique standard en contrôle de gestion (on ne compare jamais un réalisé partiel à un budget annuel complet). Résultat : Variance % ramenée à -1,18%, un écart budgétaire réaliste.

Enseignement méthodologique : ces deux anomalies illustrent une règle générale en analyse financière : un chiffre qui semble aberrant (EBITDA très négatif, écart énorme) doit toujours déclencher une vérification de la donnée source et du périmètre de comparaison avant d'être présenté — souvent, l'anomalie n'est pas dans la logique de calcul (le DAX était correct dès le départ) mais dans la donnée ou le périmètre comparé.

Chiffres clés du jeu de données final

INDICATEUR	VALEUR
Actual (période alignée, 31 mois)	72,94 M€
Budget (période alignée)	73,80 M€
Variance %	-1,18%
Revenue (Actual)	36,32 M€
COGS	13,29 M€
Opex	18,01 M€
EBITDA	5,02 M€
Marge EBITDA %	13,82%
Score Data Quality global	97,5%

07 Inventaire des fichiers du projet

FICHIER	RÔLE
scripts/generate_dataset.py	Génère les CSV bruts (avec anomalies) et le référentiel propre
data/raw_sources/*.csv	Sources simulées ERP et Excel budget, à charger en Bronze
data/reference/*.csv	Dimensions propres et table de faits de référence
notebooks/dq_checks.ipynb	Contrôles Data Quality + production des tables Silver
notebooks/load_forecast.ipynb	Chargement du scénario Forecast
warehouse/build_star_schema.sql	Construction du schéma en étoile dans le Warehouse
warehouse/refresh_star_schema.sql	Rafraîchissement des données sans recréer les tables