


Projet Cloud Data & Analytics

Customer Cohort & Churn

Comprendre la retention client dans le temps et predire le churn pour agir proactivement sur les clients a risque

Architecture technique — Customer Cohort & Churn

Pipeline cloud Azure + Databricks + Power BI — architecture medaillon (Bronze / Silver / Gold)



Orchestration quotidienne via Azure Data Factory (trigger 02h00) — alerting Azure Monitor en cas d'echec — actualisation automatique du dataset Power BI en fin de pipeline.

Domaine	CRM / Analytics client - Retail multicanal
Stack technique	Azure Data Factory - ADLS Gen2 - Databricks (PySpark) - Power BI Service
Perimetre des donnees	5 988 clients - 56 851 commandes - 4 311 820 € de CA analyse
Periode couverte	Janvier 2024 - Aout 2026
Auteur	Darryll Joseph
Date de generation du rapport	2026-08-25 16:39

Sommaire

Sommaire	2
1. Contexte et objectifs du projet	4
1.1 Problematique metier	4
1.2 Objectifs et KPIs clés	4
1.3 Glossaire metier	4
2. Architecture technique	6
2.1 Vue d'ensemble du pipeline	6
2.2 Sources de donnees - CRM	6
2.3 Ingestion - Azure Data Factory	6
2.4 Stockage - Azure Data Lake Storage Gen2	6
2.5 Traitement - Databricks (PySpark / Python)	7
2.6 Securite, gouvernance et supervision	7
3. Qualite des donnees	8
Resultats du dernier controle qualite	8
4. Construction des cohortes et analyse de retention	9
4.1 Methodologie	9
4.2 Resultats clés	9
5. Segmentation RFM	10
5.1 Methodologie	10
5.2 Resultats par segment	10
6. Modelisation du churn	11
6.1 Definition metier du churn	11
6.2 Prevention du data leakage (fuite de donnees)	11
6.3 Variables (features) utilisees	11
6.4 Resultats du modele (regression logistique)	11
6.5 Interpretation metier	12
7. Restitution — Power BI	13
7.1 Modele semantique et mesures DAX	13
7.2 Page « Retention & Cohortes »	13
7.3 Page « Churn & Segmentation RFM »	14
7.4 Actualisation et alertes	14
8. Synthese des enseignements	15
9. Recommandations et prochaines etapes	15
10. Annexes	16

10.1 Arborescence des livrables du projet	16
10.2 Glossaire technique complémentaire	16

1. Contexte et objectifs du projet

1.1 Problematique metier

L'entreprise dispose d'un CRM historisant l'ensemble des clients et de leurs commandes multicanal (site web, application mobile, marketplace, magasin partenaire). Le constat metier est le suivant : une part significative des clients cesse d'acheter apres quelques mois sans qu'aucune action proactive ne soit declenchee. L'enjeu du projet est double : **comprendre** comment la base client se retient dans le temps (analyse de cohortes) et **anticiper** quels clients presentent un risque eleve de depart (churn) afin de permettre a la Direction Marketing et Relation Client de cibler des actions de retention (offres, relances, programme de fidelite) avant que le client ne se desengage definitivement.

1.2 Objectifs et KPIs cles

Le projet vise a fournir, de maniere automatisee et actualisee quotidiennement, les indicateurs suivants :

- **Taux de retention par cohorte** : pourcentage de clients toujours actifs M+1, M+3, M+6, M+12 apres leur inscription.
- **Taux de churn** : proportion de clients n'ayant plus commande depuis plus de 90 jours.
- **CLV (Customer Lifetime Value) et ARPU** (revenu moyen par utilisateur) pour mesurer la valeur generee par la base client.
- **Segmentation RFM** (Recence, Frequence, Montant) pour prioriser les actions commerciales par typologie de client.

1.3 Glossaire metier

Cohorte

Groupe de clients partageant une meme caracteristique temporelle - ici, le mois d'inscription. L'analyse de cohortes compare le comportement de groupes de clients inscrits a des periodes differentes.

Retention

Capacite a conserver des clients actifs dans le temps. La retention a M+3 d'une cohorte est le pourcentage de ses clients ayant encore passe au moins une commande 3 mois apres leur inscription.

Churn (attrition)

Perte d'un client, defini ici comme l'absence de toute commande depuis plus de 90 jours. Le taux de churn est le pourcentage de clients eligibles (anciennete > 30 jours) concernes.

RFM

Methode de segmentation clients fondee sur 3 axes : Recence (temps ecole depuis le dernier achat), Frequence (nombre de commandes) et Montant (valeur totale depensee). Chaque axe est note de 1 (faible) a 5 (fort), la combinaison des 3 scores determinant un segment metier (ex. Champions, A Risque, Perdus).

CLV - Customer Lifetime Value

Valeur totale generee par un client sur la duree de la relation commerciale. Utilisee ici comme le montant total historique depense par client.

ARPU

Average Revenue Per User - chiffre d'affaires moyen genere par client sur une periode donnee (ici, mensuelle).

Score de risque de churn

Probabilite, estimee par un modele de machine learning (regression logistique), qu'un client n'effectue aucun achat dans les 90 prochains jours.


2. Architecture technique

2.1 Vue d'ensemble du pipeline

Le pipeline suit une architecture medaillon (Bronze / Silver / Gold), standard sur Azure Data Lake, orchestree de bout en bout par Azure Data Factory et executee sur un cluster Databricks. Chaque etape correspond a un niveau croissant de qualite et de valeur ajoutee des donnees.

Architecture technique — Customer Cohort & Churn

Pipeline cloud Azure + Databricks + Power BI — architecture medaillon (Bronze / Silver / Gold)



Orchestration quotidienne via Azure Data Factory (trigger 02h00) — alerting Azure Monitor en cas d'echec — actualisation automatique du dataset Power BI en fin de pipeline.

Figure 1 - Schema d'architecture du pipeline de bout en bout.

2.2 Sources de donnees - CRM

La source unique du projet est le CRM transactionnel (Azure SQL Database), compose de deux tables principales : **Customers** (identite, date d'inscription, region, age, canal d'acquisition) et **Orders** (commandes horodatees, montant, nombre d'articles, categorie, canal de vente). Chaque table porte une colonne *LastModifiedDate* utilisee pour l'extraction incrementale.

```
SELECT c.CustomerId AS customer_id, c.SignupDate AS signup_date, c.Region AS region,
c.Age AS age, c.AcquisitionChannel AS acquisition_channel
FROM CRM.dbo.Customers AS c
WHERE c.LastModifiedDate > (SELECT WatermarkValue FROM dbo.WatermarkTable
WHERE TableName = 'CRM.Customers');
-- Requete complete : sql/01_extract_crm.sql
```

2.3 Ingestion - Azure Data Factory

Le pipeline ADF **PL_Ingestion_CRM_to_ADLS** orchestre l'ensemble de la chaine : extraction incrementale (watermark) des tables CRM, copie au format Parquet dans la zone Bronze d'ADLS Gen2, puis declenchement sequentiel des notebooks Databricks (qualite, transformation, cohortes, scoring churn, export Gold), et enfin actualisation automatique du dataset Power BI via l'API REST Power BI. Un trigger planifie (**TR_Daily_02h00**) declenche l'execution chaque jour. En cas d'echec d'une activite, une alerte est envoyee (webhook Teams + Azure Monitor).

Fichiers livres : adf/pipeline_ingestion_crm_to_adls.json, adf/README_ADF.md

2.4 Stockage - Azure Data Lake Storage Gen2

Les donnees sont organisees en 3 zones physiques distinctes sur le compte de stockage stcohortchurnprod, chacune correspondant a un niveau de traitement :

Zone	Format	Contenu
Bronze	Parquet (brut)	Copie fidele des extractions CRM, partitionnee par date d'ingestion, historisee sans transformation
Silver	Delta Lake	Donnees nettoyees, dedupliquees, validees, enrichies (jointures, cohortes)

Zone	Format	Contenu
Gold	Delta Lake	Tables analytiques pretes a la consommation : cohortes, segments RFM, scores de churn, KPIs

2.5 Traitement - Databricks (PySpark / Python)

Le traitement est realise sur Databricks au travers de 7 notebooks executes sequentiellement par ADF, chacun correspondant a une etape du projet :

#	Notebook	Role
01	Ingestion Bronze	Lecture des Parquet ADF, ecriture en tables Delta Bronze (append)
02	Controle qualite	Completude, unicite, validite, integrite referentielle, fraicheur (voir section 3)
03	Transformation Silver	Nettoyage, typage, enrichissement, calcul du mois de cohorte
04	Construction des cohortes	Matrice de retention par cohorte mensuelle (pandas)
05	Segmentation RFM	Scores quintiles Recence/Frequence/Montant et regles de segment
06	Modelisation du churn	Entrainement et scoring d'une regression logistique (Spark ML)
07	Export Gold	Assemblage des tables finales consommees par Power BI

```
invalid_age = customers_dedup.filter((F.col('age') < 16) | (F.col('age') > 100))
invalid_amount = orders_dedup.filter(F.col('amount') <= 0)
orders_orphan = orders_valid_amount.join(valid_customer_ids, 'customer_id', 'left_anti')
if freshness_days > FRESHNESS_SLA_DAYS:
    raise Exception('Fraicheur des donnees hors SLA - pipeline interrompu.')
```

2.6 Securite, gouvernance et supervision

- Secrets (chaines de connexion, webhooks) stockes dans **Azure Key Vault**, jamais en clair dans les pipelines.
- Authentification inter-services (ADF -> Databricks, ADF -> Power BI API) via **Managed Identity**.
- Diagnostics et alertes centralises dans **Azure Monitor** / Log Analytics ; notification immediate en cas d'echec pipeline.
- Code versionne sur **GitHub**, notebooks deployes depuis un repo lie (Databricks Repos).

3. Qualite des donnees

Avant tout passage en zone Silver, 5 dimensions de qualite sont systematiquement controlees. Les lignes rejetees sont journalisees (table `quality.rejected_records`) pour audit, sans jamais etre supprimees silencieusement.

Completude — Taux de champs cles renseignes (non nuls) sur les colonnes critiques (identifiant, date, montant...).

Unicite — Absence de doublons sur les cles metier (`customer_id`, `order_id`).

Validite — Respect de plages de valeurs metier acceptables (age entre 16 et 100 ans, montant strictement positif).

Integrite referentielle — Toute commande doit reference un client existant et valide (pas de commande orpheline).

Fraicheur des donnees — Ecart entre la date de la derniere transaction chargee et la date du jour ; SLA fixe a 2 jours.

Resultats du dernier controle qualite

Indicateur	Valeur
Clients extraits (Bronze)	6 045
Doublons clients supprimes	45
Valeurs region manquantes corrigees	60
Clients rejetes (age invalide)	12
Clients valides (Silver)	5 988
Doublons commandes supprimes	80
Commandes rejetees (montant invalide)	25
Commandes rejetees (orphelines - FK)	111
Commandes valides (Silver)	56 851
Completude finale (clients / commandes)	100% / 100%
Fraicheur des donnees	1 jour(s)

4. Construction des cohortes et analyse de retention

4.1 Methodologie

Chaque client est rattache a une cohorte definie par son mois d'inscription (`cohort_month`). Pour chaque commande, on calcule le decalage en mois (`cohort_index`) entre le mois de la commande et le mois de la cohorte. La retention a $M+n$ d'une cohorte est alors le nombre de clients distincts ayant commande au decalage n , rapporte a la taille initiale de la cohorte. Cette matrice cohorte x mois est le support de la *matrice de retention* restituee dans Power BI (voir section 7).

4.2 Resultats cles

Horizon	Taux de retention moyen (pondere)
Retention a M+1	43,3 %
Retention a M+3	39,5 %
Retention a M+6	34,5 %
Retention a M+12	27,0 %

Lecture metier : environ 43,3 % des clients recommandent des le premier mois suivant leur inscription, mais ce taux se degrade progressivement pour atteindre 27,0 % un an apres l'inscription. La plus forte perte de clients intervient entre M+1 et M+3, ce qui suggere qu'une action de relance cible dans les 90 premiers jours (email de bienvenue prolonge, offre de reachat) pourrait avoir un impact disproportionne sur la retention long terme.

5. Segmentation RFM

5.1 Methodologie

Pour chaque client, 3 indicateurs sont calculés à la date d'analyse : la **recence** (nombre de jours depuis la dernière commande), la **frequence** (nombre total de commandes) et le **montant** (chiffre d'affaires cumulé). Chaque indicateur est converti en score quintile de 1 à 5 (5 = comportement le plus favorable), puis les 3 scores sont combinés selon une grille de règles métier pour affecter un segment :

Segment	Regle (scores R/F/M)	Description
Champions	R >= 4 et F >= 4 et M >= 4	Clients recents, frequents et a forte valeur
Clients Fideles	R >= 3 et F >= 3	Base solide, achats reguliers
Nouveaux Clients	R >= 4 et F <= 2	Inscrits recemment, peu d'historique
Prometteurs	R = 3 et F <= 3	Comportement moyen, a potentiel
A Risque	R <= 2 et F >= 3	Anciens bons clients, inactifs recemment
Perdus	R <= 2 et F <= 2 et M <= 2	Faible engagement sur tous les axes
Occasionnels	(autres combinaisons)	Comportement irregulier

5.2 Resultats par segment

Segment	Clients	CA genere	Taux de churn	% de la base
Champions	1 621	3 240 864 €	0,9 %	27,1 %
Clients Fideles	1 115	579 583 €	58,5 %	18,6 %
A Risque	857	400 176 €	100,0 %	14,3 %
Perdus	1 465	38 367 €	100,0 %	24,5 %
Prometteurs	552	20 934 €	100,0 %	9,2 %
Nouveaux Clients	305	20 439 €	4,6 %	5,1 %
Occasionnels	73	11 456 €	100,0 %	1,2 %

Insight cle (effet Pareto) : le segment **Champions** ne represente que 27,1 % de la base client mais genere 75,2 % du chiffre d'affaires total, avec un taux de churn quasi nul (0,9 %). A l'inverse, le segment **A Risque** (857 clients) combine un historique d'achat significatif et un taux de churn de 100,0 % : c'est la cible prioritaire pour des campagnes de reactivation, le cout d'acquisition d'un nouveau client etant generalement superieur au cout de reactivation d'un client existant.

6. Modelisation du churn

6.1 Definition metier du churn

Un client est considere en situation de churn (indicateur descriptif) s'il n'a passe **aucune commande depuis plus de 90 jours**, sous reserve d'avoir au moins 30 jours d'anciennete (pour ne pas penaliser les clients tres recents qui n'ont pas encore eu l'occasion de racheter).

6.2 Prevention du data leakage (fuite de donnees)

Un piege classique en modelisation du churn est d'entrainer le modele avec, comme variable explicative, la *recence au jour J* pour predire un label *construit a partir de cette meme recence au jour J* (le modele apprend alors une tautologie et affiche des scores artificiellement parfaits, sans valeur predictive reelle). Ce projet applique donc un **decoupage temporel out-of-time** : les variables explicatives sont calculees a une date d'observation **T0 = aujourd'hui - 90 jours** (soit le 2026-05-27), et le label (churn ou non) est determine en observant si le client a effectue un achat durant la fenetre de 90 jours suivant T0. Le modele ainsi entraine est ensuite applique aux variables calculees a la date du jour pour produire le score de risque utilise en production.

6.3 Variables (features) utilisees

Variable	Description
recency_days	Nombre de jours depuis la derniere commande
frequency	Nombre total de commandes
monetary	Chiffre d'affaires cumule genere par le client
tenure_days	Anciennete du client (jours depuis l'inscription)
avg_order_value	Panier moyen du client
order_freq_per_month	Frequence d'achat mensuelle moyenne
age	Age du client

6.4 Resultats du modele (regression logistique)

Le modele est entraine sur 4 259 clients et evalue sur un echantillon test independant de 1 420 clients (25% des donnees, split stratifie).

Metrique	Valeur
Exactitude (accuracy)	87,0 %
Precision	93,7 %
Rappel (recall)	85,2 %
Score F1	89,3 %
AUC-ROC	0,947

Matrice de confusion (echantillon test) :

	Predit : Fidele	Predit : Churn
Reel : Fidele	467	52

Reel : Churn	133	768
--------------	-----	-----

Coefficients du modele (apres standardisation des variables) :

Variable	Coefficient
recency_days	4,808
frequency	-0,164
monetary	0,360
tenure_days	-0,134
avg_order_value	-0,117
order_freq_per_month	-0,797
age	-0,137

6.5 Interpretation metier

La variable la plus influente est **recency_days** (coefficient 4.808) : plus un client est inactif depuis longtemps, plus sa probabilite de churn dans les 90 prochains jours est elevee — un resultat attendu et coherent avec la litterature sur le churn retail. Le coefficient negatif de **order_freq_per_month** confirme qu'une frequence d'achat reguliere protege du churn, meme a anciennete egale. Le modele atteint un AUC-ROC de 0,947, ce qui indique une bonne capacite de discrimination entre clients fideles et clients a risque, exploitable operationnellement pour prioriser les actions de retention. Applique a la base active, le modele identifie 3 457 clients en risque de churn eleve (score > 0,60).

7. Restitution — Power BI

Les tables Gold sont consommées par Power BI en mode **Import** via le connecteur natif Azure Databricks (SQL Warehouse dédié SQLW_Gold_PowerBI). Le dataset est actualisé automatiquement en toute fin de pipeline ADF (activité Refresh_PowerBI_Dataset, appel à l'API REST Power BI). Le rapport comporte 2 pages principales, présentées ci-dessous avec les chiffres réels issus du dernier traitement.

7.1 Modèle sémantique et mesures DAX

Extrait des mesures DAX du modèle (fichier complet : powerbi/dax_measures.dax) :

Taux de Churn % =
DIVIDE(
CALCULATE(DISTINCTCOUNT(Gold_Customer360Churn[customer_id]), Gold_Customer360Churn[is_churned]=1),
[Nb Clients Total]
)

CLV Moyen = AVERAGE(Gold_Customer360Churn[monetary])

7.2 Page « Retention & Cohortes »

Vue d'ensemble de la base client : KPIs généraux, matrice de retention par cohorte avec mise en forme conditionnelle (heatmap), évolution du chiffre d'affaires et des clients actifs, répartition régionale et synthèse qualité des données.




Figure 2 - Rapport Power BI, page « Retention & Cohortes ».

7.3 Page « Churn & Segmentation RFM »

Pilotage du risque de churn : taux de churn global, repartition et valeur des segments RFM, niveaux de risque issus du modele, churn par region et carte de performance du modele pour l'equipe data.




Figure 3 - Rapport Power BI, page « Churn & Segmentation RFM ».

7.4 Actualisation et alertes

Le dataset est rafraichi quotidiennement a l'issue du pipeline ADF. Des alertes Power BI (data-driven alerts sur carte KPI) sont configurees sur la mesure Taux de Churn % : notification automatique de l'equipe CRM si le taux depasse le seuil de 15% sur une cohorte donnee.

8. Synthèse des enseignements

- La base compte 5 988 clients valides pour 4 311 820 € de chiffre d'affaires cumulé sur la période ; 2 360 clients sont actifs (commande dans les 90 derniers jours).
- Le taux de churn global atteint 60,6 %, avec une chute de rétention marquée entre M+1 (43,3 %) et M+12 (27,0 %).
- Le segment Champions (27,1 % des clients) concentre 75,2 % du CA total avec un churn quasi nul : un effet Pareto net qui justifie un traitement VIP dédié.
- Le segment A Risque combine historique d'achat significatif et forte probabilité de départ : c'est la cible prioritaire des actions de reactivation.
- Le modèle de régression logistique (AUC-ROC = 0,947) identifie 3 457 clients à risque élevé, la recence d'achat étant de loin la variable la plus prédictive du churn.
- La qualité des données sources reste globalement bonne après nettoyage : 100,0 % de complétude clients, 111 commandes orphelines détectées et écartées.

9. Recommandations et prochaines étapes

- Déclencher une campagne de reactivation ciblée sur le segment **A Risque** (857 clients, section 5.2) avant qu'ils ne basculent en **Perdus**.
- Renforcer l'onboarding sur les 90 premiers jours (email, offre de rachat) pour limiter la chute de rétention observée entre M+1 et M+3.
- Enrichir le modèle de churn avec des variables comportementales additionnelles (taux de retour produit, interactions SAV, ouverture d'emails marketing) pour améliorer encore le pouvoir prédictif.
- Automatiser le déclenchement d'actions marketing directement depuis le score de risque (webhook Power Automate sur alerte Power BI) plutôt qu'une lecture manuelle du dashboard.
- Mettre en place un reentrainement périodique (mensuel) du modèle pour absorber la dérive des comportements d'achat (concept drift).

10. Annexes

10.1 Arborescence des livrables du projet

```
projetttt/  
■■■ data/ Extraits CRM simules (Bronze brut + Silver nettoye)  
■■■ sql/01_extract_crm.sql Requetes d'extraction incrementale CRM  
■■■ adf/ Pipeline Azure Data Factory (JSON) + README  
■■■ databricks/ 7 notebooks PySpark/Python (Bronze -> Gold)  
■■■ powerbi/  
■ ■■■■ dax_measures.dax Mesures DAX du modele semantique  
■ ■■■■ report_data/ Tables Gold (CSV/JSON) consomrees par le rapport  
■■■ analysis/ Scripts de generation (donnees, images, PDF)  
■■■ images/ Visuels du rapport Power BI + schema d'architecture  
■■■ docs/rapport_projet_...pdf Le present document
```

10.2 Glossaire technique complementaire

Architecture medaillon (Bronze/Silver/Gold)

Modele d'organisation d'un data lake en 3 couches de qualite croissante : donnees brutes, donnees nettoyes/enrichies, donnees pretes pour l'analyse.

Delta Lake

Format de table transactionnel (ACID) au-dessus de Parquet, utilise par Databricks pour garantir la fiabilite des ecritures concurrentes et l'historisation (time travel).

AUC-ROC

Aire sous la courbe ROC : mesure globale de la capacite d'un modele de classification a distinguer les 2 classes (churn / non-churn), entre 0,5 (hasard) et 1 (parfait).

Precision / Rappel

La precision mesure la part de vrais churners parmi les clients predicts churn ; le rappel mesure la part de churners reellement detectee par le modele.

Data leakage (fuite de donnees)

Erreur de modelisation ou une information indisponible au moment de la prediction reelle est utilisee lors de l'entrainement, produisant des performances artificiellement elevees (voir section 6.2).

Watermark

Valeur (generalement une date) utilisee pour ne recuperer, lors d'une extraction incrementale, que les enregistrements modifies depuis la derniere execution.