

Customer Intelligence

Rapport technique & business complet

Churn Prediction · Segmentation Client · Lead Scoring · Interprétabilité SHAP · Dashboard Power BI

Ce document détaille l'ensemble des choix techniques et métier réalisés au cours du projet, notebook par notebook, avec la justification de chaque décision de modélisation et l'explication de chaque visuel produit.

Sommaire

- 1. Introduction et objectifs
- 2. Sources de données
- 3. Analyse SQL (Étape 1)
- 4. Analyse exploratoire — EDA (Étape 2)
- 5. Feature Engineering (Étape 3)
- 6. Segmentation K-Means + PCA (Étape 4)
- 7. Prédiction du churn (Étape 5)
- 8. Lead Scoring (Étape 6)
- 9. Interprétabilité SHAP (Étape 7)
- 10. Dashboard Power BI (Étape 8)
- 11. Recommandations marketing (Étape 9)
- 12. Conclusion

1. Introduction et objectifs

Ce projet construit une plateforme d'intelligence client de bout en bout, sous l'identité fictive **Customer Intelligence**, en suivant le pipeline complet d'un projet de data science en entreprise : requêtes SQL descriptives, exploration Python, feature engineering, segmentation non supervisée, modélisation supervisée (churn et lead scoring), interprétabilité des modèles, restitution business via un dashboard Power BI, et enfin recommandations actionnables.

Trois questions business structurent l'ensemble du projet :

- **Qui sont mes clients ?** → segmentation comportementale (K-Means)
- **Qui va partir ?** → prédiction du churn (classification supervisée)
- **Quel prospect a le plus de potentiel commercial ?** → lead scoring

Le principe directeur suivi tout au long du projet a été de ne jamais accepter un résultat « par défaut » sans le questionner : plusieurs choix qui semblaient évidents au premier abord (le nombre de clusters, le modèle le plus performant) se sont révélés trompeurs à y regarder de plus près — ces cas sont documentés explicitement dans ce rapport, car ils illustrent une partie importante du travail réel d'un data analyst/scientist : interroger ses propres résultats.

2. Sources de données

Dataset	Lignes × Colonnes	Usage	Source
Telco Customer Churn (IBM)	7 043 × 21	EDA, segmentation, churn, SHAP	Kaggle (blastchar)
Leads Dataset (X Education)	9 240 × 37	Lead scoring	Kaggle (ashydv)

Le choix de deux datasets distincts (plutôt qu'un seul) est délibéré : le churn concerne des **clients déjà acquis** qui risquent de partir, alors que le lead scoring concerne des **prospects pas encore clients**. Le dataset Telco ne contient aucune notion de prospect non converti — il ne peut donc pas servir à un vrai lead scoring. La signification métier complète de chaque colonne des deux datasets est documentée séparément dans *reports/data_dictionary.pdf*.

3. Analyse SQL (Étape 1)

Avant toute manipulation en Python, les deux datasets sont chargés dans une base SQLite locale (*data/processed/customer_intelligence.db*) et interrogés avec 18 requêtes SQL répondant à des questions business précises, définies en amont plutôt que rédigées au fil de l'eau.

Pourquoi ce choix : Passer par SQL avant pandas reproduit la réalité d'un environnement professionnel où les données vivent d'abord dans un entrepôt de données interrogeable par toute l'équipe, pas uniquement par la personne qui écrit le code Python.

Principaux résultats obtenus :

Question	Résultat
Taux de churn global	26,54 % — soit 2 862 927 \$ de revenus perdus
Churn par contrat	Mensuel 42,71 % vs. 2 ans 2,83 %
Churn par paiement	Chèque électronique 45,29 % (le plus élevé)
Ancienneté moyenne	37,6 mois (non-churn) vs. 18,0 mois (churn)
Taux de conversion global (leads)	38,54 %
Conversion par source	Welingak Website 98,59 %, Reference 91,76 %
Temps sur site (converti vs non)	738,5 s vs. 330,4 s

4. Analyse exploratoire — EDA (Étape 2)

L'EDA reprend les mêmes questions business que l'étape SQL, mais avec pandas et des visualisations, dans le but explicite de repérer les problèmes de qualité de données à corriger avant le feature engineering.

4.1 — Dataset Telco Churn

Problème de type détecté : la colonne *TotalCharges* est stockée en texte, avec des chaînes vides pour les 11 clients ayant *tenure* = 0 (nouveaux clients sans historique de facturation). Corrigée via `pd.to_numeric(..., errors='coerce')`.




Fig. 1 — Distribution de l'ancienneté, des charges mensuelles et totales. La distribution de l'ancienneté est bimodale (pic de nouveaux clients et pic de clients très anciens), signe de deux dynamiques de rétention différentes dans la base.




Fig. 2 — Taux de churn par type de contrat : le contrat mensuel concentre l'essentiel du risque.




Fig. 3 — Taux de churn par méthode de paiement.




Fig. 4 — Taux de churn par type d'accès internet : la fibre optique churne deux fois plus que le DSL.




Fig. 5 — Taux de churn par tranche d'ancienneté : le risque est concentré sur les 12 premiers mois.



Fig. 6 — Matrice de corrélation entre variables numériques et churn (encodé 0/1). Corrélation négative nette entre ancienneté et churn.

4.2 — Dataset Leads

Deux problèmes structurels identifiés :

- **12 colonnes quasi constantes** (plus de 95 % d'une seule valeur, ex : *Magazine*, *Search*, *Do Not Call*) — aucune valeur prédictive.
- **5 colonnes avec plus de 45 % de valeurs manquantes** (*Lead Quality*, les 4 colonnes *Asymmetrique...*).
- Doublons de casse dans *Lead Source* ('Google' vs 'google') à nettoyer avant encodage.




Fig. 7 — Distribution des variables comportementales (visites, temps sur site, pages vues).




Fig. 8 — Taux de conversion par source d'acquisition (top 8).




Fig. 9 — Taux de conversion par dernière activité enregistrée.




Fig. 10 — Taux de conversion par profession actuelle du prospect.

5. Feature Engineering (Étape 3)

5.1 — Telco

- *TotalCharges* converti en numérique, valeurs manquantes remplacées par 0 (cohérent avec l'absence de facturation cumulée pour un nouveau client).
- *customerID* exclu (identifiant sans valeur prédictive).
- Nouvelle variable **NumAddonServices** : nombre de services additionnels souscrits (0 à 6) — proxy d'engagement client.
- Nouvelle variable **AvgMonthlySpend** = *TotalCharges* / *tenure* (avec gestion du cas *tenure* = 0) — dépense mensuelle réelle, proxy "Monetary" au sens RFM.
- Encodage : variables binaires (Yes/No) mappées en 0/1 ; variables multi-catégories encodées en one-hot avec `drop_first=True`.

Pourquoi ce choix : `drop_first=True` évite le piège de colinéarité parfaite (dummy variable trap) entre les colonnes one-hot — important pour la régression logistique, qui suppose l'indépendance des variables explicatives.

5.2 — Leads

- Suppression des 12 colonnes quasi constantes et des 5 colonnes à forte proportion de valeurs manquantes.
- Suppression de *Tags* : cette colonne est renseignée par le commercial **après** avoir traité le lead — l'utiliser créerait une fuite de données (le modèle s'entraînerait sur une information qui n'existe pas au moment réel de la prédiction).
- Suppression de *Country*, *City* et *What matters most to you in choosing a course* (dominées à plus de 70 % par une seule valeur parmi les non-manquants).
- Nettoyage de casse sur *Lead Source*, imputation des valeurs manquantes restantes (médiane pour le numérique, mode ou catégorie "Unknown" pour le catégoriel).
- Regroupement des catégories rares (moins de 1 % de fréquence) dans une catégorie "Other" pour *Lead Source* et *Last Activity*, avant encodage one-hot.

Résultat final : *telco_features* (7 043 × 33, 100 % numérique, aucune valeur manquante) et *leads_features* (9 240 × 65, 100 % numérique, aucune valeur manquante).

6. Segmentation K-Means + PCA (Étape 4)

Le clustering est réalisé sur les 32 colonnes de *telco_features* à l'exclusion de *Churn*, après standardisation (StandardScaler).

Pourquoi ce choix : *Churn* est exclu du clustering car c'est la variable qu'on cherche à expliquer plus tard : si elle influençait la formation des clusters, la segmentation ne serait plus un profil de comportement indépendant, mais une simple redite de la cible. La standardisation est nécessaire car K-Means se base sur des distances euclidiennes — sans elle, *TotalCharges* (échelle ~0-8000) écraserait *NumAddonServices* (échelle 0-6).




Fig. 11 — Méthode du coude (inertie) et score de silhouette pour $k = 2$ à 8.

6.1 — Le piège du choix automatique de k

Le score de silhouette maximal pointait vers $k = 2$ (silhouette 0,342). En examinant le profil de ce découpage, il s'est avéré que ce split séparait simplement les clients **avec internet** des clients **sans internet** : ces derniers ont mécaniquement des zéros sur une dizaine de colonnes one-hot liées à internet simultanément (*InternetService_No*, *OnlineSecurity_No internet service*, etc.), ce qui les rend artificiellement très éloignés de tous les autres clients dans l'espace des distances — un artefact de l'encodage, pas une segmentation marketing utile.

Pourquoi ce choix : $k = 4$ a été retenu à la place (silhouette 0,248, 2■ meilleur score) : la courbe du coude montre des gains décroissants après $k = 4$, et ce choix distingue plusieurs profils réels parmi les clients avec internet, qui représentent l'essentiel de la base — un résultat bien plus exploitable pour le marketing qu'un simple clivage binaire.




Fig. 12 — Projection PCA en 2D des 4 segments (le clustering lui-même est réalisé sur les 32 variables complètes, la PCA ne sert qu'à la visualisation).

Segment	Clients	Ancienneté	Dépense/mois	Services add.	Churn
Nouveaux fibre à risque	2 696 (38,3 %)	15,9 mois	73,1 \$	1,44	46,1 %
DSL engagement mensuel	682 (9,7 %)	31,7 mois	42,0 \$	2,56	24,9 %
Premium fidèles	2 139 (30,4 %)	54,6 mois	92,6 \$	4,07	16,0 %
Économes sans internet	1 526 (21,7 %)	30,6 mois	21,1 \$	0,00	7,4 %




Fig. 13 — Taux de churn réel par segment (validation externe : le churn n'a pas servi à créer les clusters, mais varie fortement d'un segment à l'autre — preuve que la segmentation capture un vrai signal métier).

7. Prédiction du churn (Étape 5)

Trois modèles sont entraînés sur *telco_features* : Logistic Regression, Random Forest et XGBoost, avec un split train/test stratifié (80/20) pour préserver le taux de churn de 26,5 % dans les deux ensembles.

Pourquoi ce choix : Le déséquilibre de classes (26,5 % de churn) rend l'accuracy trompeuse : un modèle prédisant toujours "pas de churn" aurait 73,5 % de bonnes réponses sans être utile. Chaque modèle est donc configuré pour pondérer davantage la classe minoritaire (`class_weight='balanced'` pour LogReg/RF, `scale_pos_weight` pour XGBoost), et l'évaluation se base sur precision/recall/F1/ROC-AUC plutôt que sur l'accuracy seule.

Modèle	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0,740	0,507	0,781	0,615	0,841
Random Forest	0,764	0,550	0,623	0,584	0,827
XGBoost	0,747	0,515	0,781	0,621	0,839




Fig. 14 — Comparaison des 4 métriques clés entre les 3 modèles.




Fig. 15 — Courbes ROC des 3 modèles.




Fig. 16 — Matrices de confusion (Random Forest a la meilleure accuracy mais le plus faible recall — c'est trompeur si on ne regarde que l'accuracy).

Pourquoi XGBoost a été retenu

Le recall a été choisi comme critère principal de sélection : dans un contexte de rétention, rater un client qui va réellement churner (faux négatif) coûte plus cher qu'une fausse alerte (faux positif, qui ne coûte qu'une offre de rétention envoyée à tort).

Logistic Regression et XGBoost obtiennent exactement le même recall (0,781) — une première règle de sélection basée uniquement sur `idxmax()` avait arbitrairement tranché pour Logistic Regression à cause de l'ordre d'insertion dans le dictionnaire Python, ce qui n'est pas un critère de décision valable.

Pourquoi ce choix : La règle a été corrigée pour départager les égalités de recall par le F1-score (équilibre precision/recall) : XGBoost a un F1 légèrement supérieur (0,621 vs 0,615), et présente l'avantage d'être un modèle à base d'arbres, ce qui permettra une interprétation SHAP plus rapide et plus

standard (TreeExplainer) à l'étape suivante.

8. Lead Scoring (Étape 6)

Le lead scoring est techniquement le même problème de classification binaire que le churn : les fonctions `split_data`, `train_logistic_regression`, `train_random_forest`, `train_xgboost` et `evaluate_model` de `src/churn_model.py` sont réutilisées telles quelles sur `leads_features`, cible `Converted`.

Modèle	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0,802	0,724	0,787	0,754	0,877
Random Forest	0,797	0,721	0,772	0,746	0,870
XGBoost	0,823	0,751	0,806	0,778	0,894

Pourquoi ce choix : Le dataset Leads est moins déséquilibré (38,5 % de conversion contre 26,5 % de churn), donc le F1-score est utilisé directement comme critère de sélection. XGBoost domine clairement cette fois sur toutes les métriques, sans ambiguïté de départage.




Fig. 17 — Taux de conversion réel par niveau de priorité (validation métier) : Froid 8,4 %, Tiède 37,5 %, Chaud 80,1 %.

La courbe de gain cumulé

Le score de conversion (0 à 100) est calculé pour chaque lead, puis les leads sont triés par score décroissant et répartis en 10 tranches égales (déciles) pour mesurer combien de conversions réelles sont captées en ne contactant que les leads les mieux notés.

Tranche	Leads	Conversions réelles	% leads contactés (cumulé)	% conversions captées (cumulé)
1 (meilleurs scores)	185	171	10,0 %	24,0 %
2	185	153	20,0 %	45,5 %
3	185	142	30,0 %	65,4 %
4	185	92	40,0 %	78,4 %

Tranche	Leads	Conversions réelles	% leads contactés (cumulé)	% conversions captées (cumulé)
5	184	74	50,0 %	88,8 %
6	185	31	60,0 %	93,1 %
7	185	26	70,0 %	96,8 %
8	185	11	80,0 %	98,3 %
9	185	8	90,0 %	99,4 %
10 (pires scores)	184	4	100,0 %	100,0 %

Comment lire ce tableau : la tranche 1 contient les 185 leads avec le meilleur score — parmi eux, 171 ont réellement converti. En ne contactant que ces 10 % de leads les mieux notés, l'équipe commerciale capte déjà 24 % de toutes les ventes potentielles. Le nombre de conversions réelles diminue régulièrement de 171 (tranche 1) à 4 (tranche 10), preuve que le score classe effectivement bien les leads du plus au moins prometteur.




Fig. 18 — Courbe de gain cumulé : la courbe du modèle reste largement au-dessus de la diagonale du ciblage aléatoire.

Message business clé : contacter les 40 % de leads les mieux scorés permet de capter 78,4 % des conversions réelles — un gain d'efficacité commercial majeur par rapport à un ciblage non priorisé.

9. Interprétabilité SHAP (Étape 7)

SHAP (SHapley Additive exPlanations) répartit l'écart entre la prédiction moyenne du modèle et la prédiction d'un individu donné entre toutes les variables, selon leur contribution réelle — ce qui rend un modèle "boîte noire" comme XGBoost explicable. `shap.TreeExplainer` est utilisé car il est optimisé (rapide et exact) pour les modèles à base d'arbres.

9.1 — Modèle de churn




Fig. 19 — Beeswarm plot : importance et direction de l'effet de chaque variable sur la prédiction de churn (rouge = valeur haute, bleu = valeur basse).




Fig. 20 — Classement des variables par importance moyenne absolue.

Variable	Importance SHAP moyenne
Contract_Two year	0,616
tenure	0,535
InternetService_Fiber optic	0,295
Contract_One year	0,280
AvgMonthlySpend	0,209
PaymentMethod_Electronic check	0,201
TotalCharges	0,171
MonthlyCharges	0,148

Le contrat 2 ans et l'ancienneté dominent très largement — cohérent avec les résultats SQL et l'EDA.




Fig. 21 — Waterfall plot pour le client le plus à risque du jeu de test (probabilité de churn prédite : 97,8 %). Chaque barre montre la contribution d'une variable, en partant de la prédiction moyenne $E[f(x)]$.




Fig. 22 — Waterfall plot pour le client le moins à risque (probabilité prédite : 0,2 %).

9.2 — Modèle de lead scoring




Fig. 23 — Beeswarm plot pour le modèle de lead scoring.




Fig. 24 — Classement des variables par importance moyenne absolue.

Variable	Importance SHAP moyenne
Total Time Spent on Website	1,015
What is your current occupation_Unknown	0,506
Last Activity_SMS Sent	0,370
Last Notable Activity_SMS Sent	0,334
Specialization_Not Specified	0,319
Lead Origin_Lead Add Form	0,311
Occupation_Working Professional	0,280
Page Views Per Visit	0,268

Le temps passé sur le site domine très largement (près de 2 fois plus important que la 2^{ème} variable) — confirme l'insight SQL de l'étape 1.




Fig. 25 — Waterfall plot pour le lead le plus prometteur (probabilité de conversion prédite : 99,7 %).




Fig. 26 — Waterfall plot pour le lead le moins prometteur (probabilité prédite : 0,3 %).

Note technique — lecture des graphiques SHAP

Lorsque le nombre de variables dépasse la limite d'affichage (`max_display`), SHAP regroupe automatiquement les variables les moins importantes restantes dans une ligne « *Sum of N other features* » plutôt que de les masquer silencieusement — un choix de la librairie qui garantit que le graphique reste honnête sur le fait que ces variables ont quand même un effet cumulé, tout en restant lisible.

10. Dashboard Power BI (Étape 8)

Le dashboard final comprend 3 pages, alimentées par deux tables exportées (src/export_dashboard_data.py) : *telco_dashboard.csv* (pages 1 et 2) et *leads_dashboard.csv* (page 3).

Pourquoi ce choix : Contrairement à l'évaluation des modèles (faite uniquement sur le jeu de test, 20 % des données, pour une mesure de performance non biaisée), le dashboard applique le modèle final à **l'ensemble** de la population de clients/leads — c'est la pratique standard en production : on évalue un modèle sur un échantillon tenu à l'écart, mais on l'utilise ensuite pour scorer tout le monde.

- **ChurnRiskPct** : probabilité de churn prédite par XGBoost pour chaque client, en pourcentage.
- **Segment** : nom lisible du cluster K-Means de chaque client (ex : "Nouveaux fibre à risque").
- **LeadScore / Priority** : score de conversion prédit (0-100) et son niveau (Chaud/Tiède/Froid).

Page 1 — Vue d'ensemble Churn




Fig. 27 — Capture réelle du dashboard : KPIs globaux, churn par contrat/paiement/accès internet/ancienneté, table des clients à plus haut risque triée par score décroissant.

Page 2 — Segmentation Clients




Fig. 28 — Répartition des 4 segments, taux de churn par segment, profil détaillé (ancienneté, dépense, services additionnels).

Page 3 — Lead Scoring

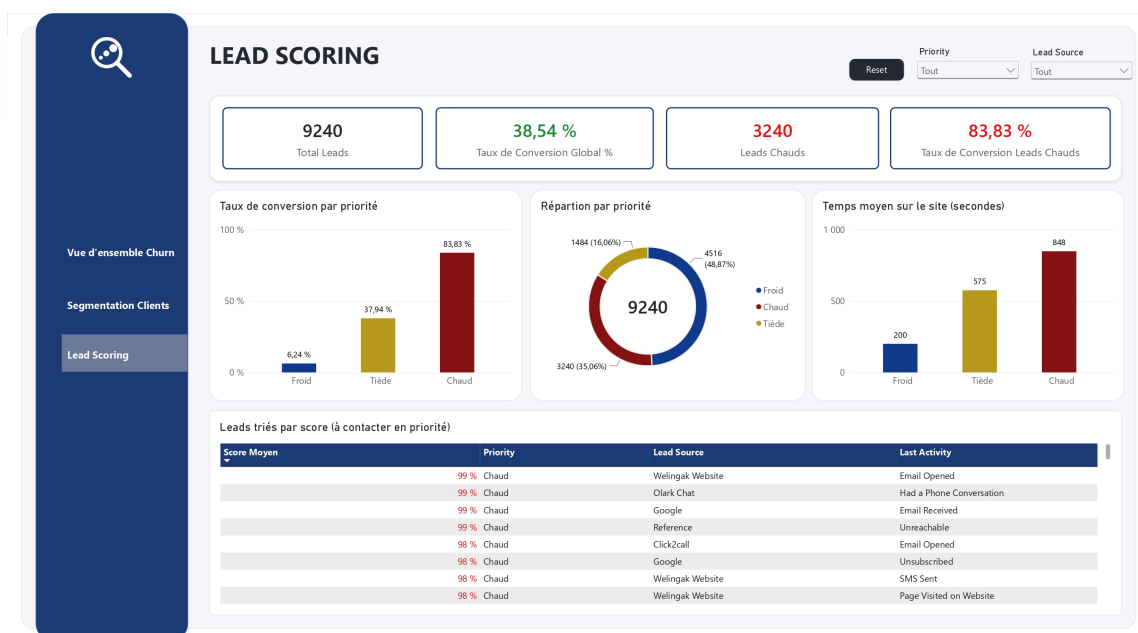


Fig. 29 — Taux de conversion et temps moyen sur le site par priorité, répartition des leads, table triée par score décroissant (liste d'appel commerciale).

Audiences par page

Page	Adressée à	Usage
Vue d'ensemble Churn	Direction / management	Diagnostic global, réunion de pilotage
Segmentation	Équipe marketing / CRM	Construction de campagnes différenciées par segment
Lead Scoring	Équipe commerciale	Liste d'appel priorisée, usage quotidien

11. Recommandations marketing (Étape 9)

Actions par segment

Segment	Constat	Action recommandée
Nouveaux fibre à risque (38,3 %, churn 46,1 %)	Récents, peu de services, contrat mensuel	Rétention immédiate : services offerts temporairement, incitation contrat 1 an
DSL engagement mensuel (9,7 %, churn 24,9 %)	Valeur modérée, contrat mensuel	Upsell services + remise migration contrat annuel
Premium fidèles (30,4 %, churn 16,0 %)	Forte valeur, très engagés	Programme de fidélité, cross-sell (pas de rétention d'urgence)
Économes sans internet (21,7 %, churn 7,4 %)	Stable, faible valeur	Priorité basse, cross-sell léger uniquement

Priorisation commerciale

- Contacter en priorité les leads "Chauds" (35,1 % du volume, conversion réelle 80,1 %).
- Réallouer le budget marketing vers les sources "Reference" et "Welingak Website" (conversion > 90 %) plutôt que "Google"/"Direct Traffic".
- Le temps passé sur le site étant le facteur le plus prédictif, envisager une relance automatique déclenchée par un seuil de temps sur le site.

Pistes futures

- Réentraîner les modèles périodiquement (risque de drift dans le temps).
- A/B tester les actions de rétention sur "Nouveaux fibre à risque" avant déploiement à grande échelle.
- Enrichir le lead scoring avec des données CRM supplémentaires (historique d'appels).

12. Conclusion

Ce projet couvre l'intégralité d'un cycle de data science appliqué à la relation client : de la requête SQL la plus simple jusqu'à la recommandation business actionnable, en passant par la modélisation supervisée et non supervisée et l'interprétabilité des modèles. Les compétences démontrées incluent : SQL, nettoyage et feature engineering avec pandas, clustering (K-Means, PCA), classification (régression logistique, forêts aléatoires, gradient boosting), gestion du déséquilibre de classes, interprétabilité (SHAP), construction de dashboard (Power BI, DAX), et traduction de résultats techniques en décisions business.

Un fil conducteur traverse l'ensemble du projet : chaque résultat automatique (le meilleur k, le meilleur modèle) a été vérifié plutôt qu'accepté tel quel, ce qui a permis d'éviter deux pièges classiques (segmentation triviale par artefact d'encodage, départage arbitraire d'égalité de recall) et d'aboutir à des résultats réellement exploitables pour l'entreprise fictive Customer Intelligence.