

Sales Forecasting & Experimentation

Prévision des ventes et A/B testing — de la donnée brute au dashboard interactif

SQL · DuckDB · Python · Statsmodels · Prophet · SciPy · Streamlit · Plotly

Rapport technique et business

Données réelles — Rossmann Store Sales & Marketing A/B Testing (Kaggle)
Septembre 2026

Sommaire

1. Contexte et objectifs métier	4
1.1 Questions business traitées	4
2. Sources de données	4
2.1 Rossmann Store Sales (forecasting)	4
2.2 Marketing A/B Testing (expérimentation)	4
3. Architecture et méthodologie	5
3.1 Choix techniques et justifications	5
4. Chargement et contrôle qualité (SQL)	5
4.1 Résultats du contrôle qualité	5
4.2 KPIs globaux (magasins ouverts uniquement)	5
5. Analyse exploratoire (EDA)	6
5.1 Tendance globale	6
5.2 Saisonnalité hebdomadaire	6
5.3 Saisonnalité mensuelle et décomposition	7
5.4 Effets promotions, jours fériés, vacances scolaires	7
5.5 CA par type de magasin et assortiment	8
5.6 Sélection des magasins pour le forecasting	9
6. Feature engineering temporel	9
6.1 Variables construites	9
6.2 Corrélations avec les ventes (magasins sélectionnés)	9
6.3 Split entraînement / test	10
7. Forecasting : SARIMA vs Prophet	10
7.1 Stationnarité (test ADF)	10
7.2 Modèle SARIMA	10
7.3 Modèle Prophet	11
7.4 Comparaison des modèles	11
8. A/B Testing	12
8.1 Échantillon	12
8.2 Test du χ^2 d'indépendance	13
8.3 Z-test de proportions et lift	13
8.4 Taille d'effet et puissance statistique	13

8.5 Effet dose (exploratoire)	14
8.6 Interprétation et recommandation business	14
9. Dashboard Streamlit	14
9.1 Onglet Ventes	14
9.2 Onglet Forecasting	15
9.3 Onglet A/B Testing	15
9.4 Lancement	15
10. Stack technique et structure du projet	15
10.1 Structure du dépôt	15
11. Limites et pistes d'amélioration	15
12. Conclusion	16
Annexe — Glossaire	16

1. Contexte et objectifs métier

Ce projet reproduit, de bout en bout, un cas d'usage classique en *data analytics* / *data science* retail : une enseigne multi-magasins veut (1) **anticiper ses ventes** pour mieux piloter ses stocks, son staffing et sa trésorerie, et (2) **valider statistiquement** l'impact d'une initiative marketing avant de la généraliser. Les deux volets sont traités séparément avec des jeux de données réels et indépendants, puis réunis dans un dashboard interactif unique.

L'objectif du projet est double : démontrer une chaîne de traitement complète et réaliste (**SQL** → **Python** → **statistiques** → **forecasting** → **A/B testing** → **restitution**), et produire des conclusions **interprétables par un décideur non technique**, pas seulement des métriques de modèle.

1.1 Questions business traitées

- Quelle est la tendance et la saisonnalité des ventes ? Quels leviers (promotions, jours fériés, type de magasin) les font varier ?
- Peut-on prévoir les ventes à 6 semaines avec une précision suffisante pour la planification d'approvisionnement, et avec quelle marge d'incertitude ?
- Une nouvelle initiative publicitaire augmente-t-elle significativement le taux de conversion, et de combien ?
- Comment mettre ces résultats à disposition des équipes métier sans dépendre d'un notebook ?

2. Sources de données

Aucune donnée synthétique n'a été utilisée : les deux jeux de données sont réels, publics, et téléchargés depuis Kaggle.

2.1 Rossmann Store Sales (forecasting)

- **1 115 magasins** Rossmann (Allemagne), ventes **journalières** du **01/01/2013** au **31/07/2015** (soit **1 017 209 lignes**).
- Variables : ventes, nombre de clients, ouverture/fermeture, promotion en cours, jour férié national, vacances scolaires, type de magasin (a-d), assortiment (a/b/c), distance à la concurrence.
- Choisi plutôt que Walmart (hebdomadaire) pour sa granularité journalière, plus riche pour le feature engineering temporel et les modèles SARIMA/Prophet.

2.2 Marketing A/B Testing (expérimentation)

- **588 101 utilisateurs** réels exposés soit à une publicité (**ad**), soit à un message neutre de contrôle (**psa** — Public Service Announcement).
- Variable cible : conversion (booléen). Variables additionnelles : nombre de publicités vues, jour/heure de pic d'exposition.
- Dataset indépendant du précédent, choisi pour sa thématique marketing directement transposable à un cas de test A/B produit ou promotionnel.

Note méthodologique

Le groupe « psa » ne représente que 4 % de l'échantillon (répartition réelle du dataset, pas un design 50/50). Ce déséquilibre est pris en compte dans l'analyse de puissance statistique (section 8.4) plutôt qu'ignoré.

3. Architecture et méthodologie

Le projet suit un pipeline en 7 étapes, chacune produisant un livrable vérifiable (requêtes SQL, notebook exécuté sans erreur, fichier de données, application) avant de passer à la suivante :

- **SQL / DuckDB** — chargement, contrôle qualité, agrégations de référence.
- **EDA Python** — tendances, saisonnalité, effets promo/jours fériés.
- **Feature engineering temporel** — variables calendaires, lags, moyennes mobiles.
- **Forecasting** — SARIMA et Prophet, comparés sur métriques d'erreur standard.
- **A/B testing** — tests d'hypothèse, taille d'effet, puissance statistique.
- **Dashboard Streamlit** — restitution interactive pour un utilisateur non technique.

3.1 Choix techniques et justifications

Choix	Justification
DuckDB plutôt qu'un SGBD comme PostgreSQL	PostgreSQL analytique embarqué, zéro installation, lit les CSV nativement, performant sur ~1M lignes en local.
8 magasins représentatifs pour le forecasting	entraîner 2 modèles × 1115 magasins n'apporterait pas plus de valeur pédagogique et technique
SARIMA (statistiques) de référence	(statistique, univarié) confronté à un modèle moderne conçu pour les séries business avec ruptures (prophet)
Split chronologique (42 derniers jours de test)	distance temporelle et donnerait une estimation d'erreur irréaliste ; on simule une vraie situation
Dashboard en Python	exécutable localement sans licence, avec le même niveau de filtres interactifs et de visualisations qu'un dashboard

4. Chargement et contrôle qualité (SQL)

Les fichiers `train.csv`, `store.csv` et `marketing_AB.csv` sont chargés dans une base DuckDB unique (`data/processed/sales.duckdb`) via `src/load_data.py`. Trois fichiers SQL (`sql/01` à `03`) documentent ensuite les contrôles qualité, les KPIs globaux et les agrégations temporelles de référence.

4.1 Résultats du contrôle qualité

- Plage de dates : **2013-01-01** → **2015-07-31**, 1 115 magasins, 1 017 209 lignes.
- **Aucune valeur nulle ni négative** sur les ventes.
- **172 817 jours de fermeture** (17 % des lignes) — magasins fermés le dimanche pour la plupart, jours fériés, travaux.
- 54 lignes « ouvert » avec 0 vente — anomalie mineure (probablement fermeture non déclarée), conservée telle quelle car négligeable (0,005 % des lignes) et sans impact sur les analyses agrégées.

4.2 KPIs globaux (magasins ouverts uniquement)

Indicateur	Valeur
CA total (période)	≈ 5,87 milliards €
Panier moyen (CA / clients)	9,12 €
CA moyen — jours sans promo	5 929 € / magasin / jour
CA moyen — jours avec promo	8 228 € / magasin / jour

Indicateur	Valeur
Effet promo (lift)	+38,8 %

Lecture business : l'effet promotionnel est net et immédiat (+38,8 % de CA moyen les " jours de promotion), ce qui en fait un signal important à intégrer dans tout modèle de prévision — c'est précisément ce qui différencie SARIMA (univarié, sans cette information) de Prophet (avec régresseur promo) en section 7.

5. Analyse exploratoire (EDA)

Notebook : notebooks/01_eda.ipynb. Objectif : comprendre la structure de la série avant toute modélisation — tendance, saisonnalités multiples, effets de rupture — et sélectionner des magasins représentatifs pour le forecasting.

5.1 Tendance globale




Figure 1 — CA total journalier, tous magasins confondus (2013-2015). Méthode : somme SQL des ventes par date. **Lecture** : tendance globale stable sur 2,5 ans, avec un pic net fin décembre chaque année (effet Noël) et des oscillations hebdomadaires très marquées (creux récurrents = dimanches, où la majorité des magasins sont fermés).

5.2 Saisonnalité hebdomadaire




Figure 2 — CA moyen par jour de la semaine (magasins ouverts uniquement). Méthode : moyenne SQL groupée par jour de semaine. **Lecture** : les ventes sont globalement stables du lundi au vendredi, avec un pic net le samedi (dernières courses

avant fermeture dominicale) — le seul jour au niveau visiblement plus haut sur le graphique.

5.3 Saisonnalité mensuelle et décomposition




Figure 3 — CA total mensuel. **Lecture** : pics de fin d'année (novembre-décembre) récurrents sur les 3 années, cohérents avec un pic de consommation avant les fêtes.




Figure 4 — Décomposition additive (statsmodels seasonal_decompose, période=7 jours). Méthode : la série journalière est décomposée en tendance (moyenne mobile lissée), saisonnalité (motif hebdomadaire répété) et résidu (ce qui reste inexpliqué). **Lecture** : la composante « Trend » est globalement stable avec des pics ponctuels de fin d'année ; la composante « Seasonal » montre un motif hebdomadaire très régulier et dominant ; le résidu reste contenu (quelques valeurs extrêmes isolées, correspondant à des jours fériés atypiques), ce qui confirme que la saisonnalité hebdomadaire explique l'essentiel de la variance court terme.

5.4 Effets promotions, jours fériés, vacances scolaires




Figure 5 — CA moyen selon promo / jour férié / vacances scolaires. **Lecture :** effet promo net (+38,8 %, cohérent avec la section 4.2) ; l'effet « jour férié » est à interpréter avec prudence (peu d'observations « ouvert » ces jours-là, la majorité des magasins fermant) ; l'effet vacances scolaires est plus modéré.

5.5 CA par type de magasin et assortiment




Figure 6 — CA moyen par type de magasin (a-d) et assortiment (a/b/c). Méthode : jointure SQL entre sales et stores, moyenne groupée.

Type	Assortiment	CA moyen (€)	Nb magasins
b	c	17 970	1
b	a	11 134	7
b	b	8 639	9
a	c	7 573	221
d	c	7 043	220
c	c	7 038	71
c	a	6 835	77
a	a	6 538	381
d	a	6 434	128

Insight business : le type de magasin « b » ne représente que **17 magasins sur 1 115 (1,5 %)** mais affiche un CA moyen 1,5 à 2,7 fois supérieur aux autres types — ce sont vraisemblablement des formats plus grands ou des emplacements premium. Un pilotage opérationnel différencié (stocks, staffing) pour ce segment serait pertinent plutôt qu'une politique uniforme.

5.6 Sélection des magasins pour le forecasting

Trois magasins à historique complet (942 jours, sans trou) ont été sélectionnés aux 10^e, 50^e et 90^e percentiles de CA moyen, pour représenter un profil faible / moyen / fort volume :

Magasin	Profil	CA moyen/jour (€)	Jours ouverts / total
373	Faible volume	3 737	777 / 942
97	Volume moyen	5 551	780 / 942
599	Fort volume	8 131	784 / 942

6. Feature engineering temporel

Notebook : notebooks/02_feature_engineering.ipynb. Construction des variables utilisées comme régresseurs (Prophet) et pour l'analyse exploratoire des dépendances temporelles, à partir des 3 magasins sélectionnés — **tous les jours sont conservés, y compris les fermetures** (ventes=0), car c'est une information réelle (fermeture dominicale) et cela garantit une fréquence journalière continue, nécessaire pour les lags et pour SARIMA.

6.1 Variables construites

- **Calendaires** : année, mois, jour, jour de la semaine, semaine de l'année, week-end, début/fin de mois.
- **Lags** : ventes à j-1, j-7, j-14.
- **Moyennes / écarts-types mobiles** : fenêtres de 7, 14 et 30 jours, calculées **sans fuite de données** (décalage `shift(1)` avant le `rolling()`, pour n'utiliser que des valeurs strictement passées).




Figure 7 — Magasin 599 (fort volume) : ventes journalières vs moyenne mobile 7 jours décalée. **Lecture** : la moyenne mobile lisse le bruit hebdomadaire et suit les variations de fond de la série — c'est cette variable qui alimente ensuite les modèles en tant que proxy de « tendance récente ».

6.2 Corrélations avec les ventes (magasins sélectionnés)

Variable	Corrélation avec ventes
sales_lag_14 (j-14)	0,804
sales_lag_7 (j-7)	0,696
sales_rollmean_14	0,477
sales_rollmean_30	0,472

Variable	Corrélation avec ventes
sales_rollmean_7	0,444
is_promo	0,420
sales_lag_1 (j-1)	0,132
is_school_holiday	0,090
is_weekend	-0,402

Insight technique : contre-intuitivement, **sales_lag_1** est peu corrélé (0,132) alors que **sales_lag_7** et **sales_lag_14** le sont fortement (0,70 et 0,80). C'est cohérent avec la saisonnalité hebdomadaire dominante identifiée en EDA : la veille (j-1) peut être un dimanche fermé (vente=0) suivi d'un lundi ouvert, ce qui casse la corrélation jour-à-jour, alors que « le même jour la semaine précédente » (j-7/j-14) compare des situations d'ouverture comparables. **is_weekend** est corrélé négativement (-0,40), reflet direct des fermetures dominicales.

6.3 Split entraînement / test

Split **chronologique** (pas de mélange aléatoire) : les **42 derniers jours** de chaque magasin constituent le jeu de test, le reste l'entraînement — soit environ 870 jours d'entraînement et 42 jours de test par magasin, pour un total de 2 736 lignes après retrait de la période de « warm-up » nécessaire au calcul des lags/moyennes mobiles.

7. Forecasting : SARIMA vs Prophet

Notebook : notebooks/03_forecasting.ipynb. Pour chacun des 3 magasins, deux modèles sont entraînés sur la période d'entraînement puis évalués sur les 42 jours de test, avec intervalles de confiance à 95 %.

7.1 Stationnarité (test ADF)

Magasin	Statistique ADF	p-value	Conclusion
97 (volume moyen)	-4,96	0,0000	Stationnaire
373 (faible volume)	-4,64	0,0001	Stationnaire
599 (fort volume)	-5,76	0,0000	Stationnaire

Les trois séries sont stationnaires (p-value < 0,05 au test de Dickey-Fuller augmenté) grâce à la forte saisonnalité hebdomadaire qui domine le signal — SARIMA n'a donc pas eu besoin d'une différenciation forte pour stabiliser la moyenne.

7.2 Modèle SARIMA

Les ordres (p, d, q) (P, D, Q, s=7) sont sélectionnés automatiquement par `pmdarima.auto_arma` (recherche pas-à-pas minimisant l'AIC, saisonnalité hebdomadaire s=7), puis le modèle final est ajusté avec `statsmodels.SARIMAX` pour obtenir les intervalles de confiance.

Magasin	Ordre retenu
97 (volume moyen)	SARIMA(5,1,0)(2,0,0)[7]
373 (faible volume)	SARIMA(1,1,0)(2,0,1)[7]

Magasin	Ordre retenu
599 (fort volume)	SARIMA(0,0,1)(1,0,2)[7]

Important : ce SARIMA est *univarié* — il n'utilise que l'historique des ventes, sans connaître à l'avance les jours de promotion ou de vacances à venir. C'est un choix délibéré pour disposer d'un modèle de référence purement statistique, au prix d'un désavantage structurel face à Prophet (section 7.4).

7.3 Modèle Prophet

Prophet est entraîné avec trois **régresseurs exogènes** connus à l'avance sur l'horizon de prévision : `is_promo`, `is_school_holiday` et `is_weekend`, en plus de ses composantes de saisonnalité hebdomadaire et annuelle natives. L'intervalle de confiance à 95 % est calculé nativement par le modèle (échantillonnage de l'incertitude sur la tendance et les composantes saisonnières).

7.4 Comparaison des modèles

Magasin	Modèle	RMSE	MAE	MAPE
97 (volume moyen)	SARIMA	2 344	1 945	28,34 %
97 (volume moyen)	Prophet	849	621	9,28 %
373 (faible volume)	SARIMA	1 071	923	22,61 %
373 (faible volume)	Prophet	388	298	6,46 %
599 (fort volume)	SARIMA	1 491	1 164	14,27 %
599 (fort volume)	Prophet	952	709	7,97 %

MAPE moyen (Mean Absolute Percentage Error, moyenne des 3 magasins) : **21,7 %** pour SARIMA contre **7,9 %** pour Prophet — soit une erreur relative **~2,7 fois plus faible** avec Prophet, de façon consistante sur les trois profils de magasin (lignes surlignées ci-dessus = meilleur modèle par magasin).




Figure 8 — MAPE par magasin et par modèle (plus bas = meilleur). Prophet domine systématiquement, avec un écart particulièrement marqué sur le magasin à volume moyen.




Figure 9 — Prévisions vs réel avec intervalles de confiance à 95 %, pour les 3 magasins. **Lecture** : les deux modèles suivent la saisonnalité hebdomadaire (dents de scie visibles), mais l'intervalle de confiance **SARIMA (bleu)** s'élargit fortement sur l'horizon de 42 jours (l'incertitude se compose jour après jour, sans information exogène pour la contraindre), alors que l'intervalle **Prophet (orange)** reste resserré et mieux centré sur la réalité, en particulier lors des pics de promotion que Prophet anticipe via son régresseur dédié.

Pourquoi Prophet l'emporte : explication

- **Information disponible** : Prophet « sait » à l'avance quels jours de test seront des jours de promotion (+38,8 % de CA en moyenne, section 4.2) ; SARIMA univarié ne peut que lisser un comportement moyen et rate les pics ponctuels.
- **Structure du modèle** : Prophet décompose explicitement tendance + saisonnalités (hebdo/an) + régresseurs, ce qui correspond bien à une série au comportement additif et interprétable — exactement le pattern observé en décomposition (Figure 4).
- **Robustesse de l'incertitude** : sans variable explicative des ruptures futures, un modèle ARIMA doit refléter cette ignorance par un intervalle de confiance large et croissant avec l'horizon — ce qui est mathématiquement correct mais peu exploitable en pratique à 42 jours.

Limite reconnue de la comparaison

Ce comparatif favorise structurellement Prophet, qui dispose de régresseurs que SARIMA n'a pas reçus dans cette implémentation. Une comparaison strictement équitable utiliserait un **SARIMAX** (SARIMA + régresseurs exogènes identiques). Le choix actuel reflète plutôt un cas d'usage réel : Prophet a été conçu pour intégrer facilement des connaissances métier (calendrier promotionnel), ce qui explique en partie sa popularité en contexte business.

8. A/B Testing

Notebook : notebooks/04_ab_testing.ipynb. Question testée : la publicité (ad) augmente-t-elle significativement le taux de conversion par rapport au message de contrôle (psa) ?

8.1 Échantillon

Groupe	n	Conversions	Taux de conversion	IC 95 %
ad	564 577	14 423	2,55 %	[2,51 % ; 2,60 %]
psa (contrôle)	23 524	420	1,79 %	[1,62 % ; 1,95 %]

8.2 Test du χ^2 d'indépendance

H_0 : le taux de conversion est indépendant du groupe. Résultat : $\chi^2 = 54,01$, **p-value = $2,0 \times 10^{-13}$** . La p-value est très inférieure au seuil de 5 % → **H_0 est rejetée** : le groupe a un effet statistiquement significatif sur la conversion.

8.3 Z-test de proportions et lift

Le χ^2 confirme la dépendance mais ne donne pas de direction. Le z-test de proportions apporte le sens et un intervalle de confiance sur l'écart : **$Z = 7,37$, p-value = $1,71 \times 10^{-13}$** .

Indicateur	Valeur
Lift absolu	+0,77 point de %
Lift relatif	+43,1 %




Figure 10 — Taux de conversion par groupe avec intervalles de confiance à 95 %. **Lecture** : les intervalles ne se chevauchent pas, ce qui confirme visuellement la significativité statistique du résultat.

8.4 Taille d'effet et puissance statistique

Indicateur	Valeur	Interprétation
Taille d'effet (Cohen's h)	0,053	Très faible en valeur absolue
Puissance statistique atteinte	1,000	Effet détecté de façon quasi certaine

Cohen's h est faible (0,053) car la conversion publicitaire reste un événement rare par nature (~2 %) : l'effet est petit *en valeur absolue par utilisateur*. Mais avec des échantillons de cette taille (> 20 000 par groupe), la puissance statistique atteint **1,000** : même un petit effet réel est détecté de façon quasi certaine. **C'est la significativité statistique qui est robuste ici, pas nécessairement l'ampleur métier**

de l'effet — nuance essentielle pour ne pas sur-interpréter un p-value extrême comme « effet énorme ».

8.5 Effet dose (exploratoire)




Figure 11 — Taux de conversion selon le nombre de publicités vues (groupe ad uniquement). **Lecture** : tendance nettement croissante — de <1 % pour les utilisateurs peu exposés à ~17 % pour les plus exposés.

Prudence méthodologique

Ce graphique **n'est pas un test A/B** (pas de randomisation sur le nombre de publicités vues) et ne doit pas être lu comme un effet causal. Le volume de publicités est mesuré sur toute la période, y compris après une éventuelle conversion, et un utilisateur plus engagé peut à la fois voir plus de publicités et convertir davantage (**causalité inverse / facteur de confusion**). Seul le contraste ad vs psa (randomisé) permet une lecture causale fiable.

8.6 Interprétation et recommandation business

- Effet **hautement significatif et robuste** ($p \approx 2 \times 10^{-13}$, puissance = 1,0).
- Lift relatif **+43,1 %** de conversion, avec IC 95 % ne se chevauchant pas — la publicité fonctionne, sur un critère purement statistique.
- **Recommandation** : le déploiement à plus grande échelle est statistiquement justifié. La décision finale doit toutefois intégrer le **coût d'acquisition** par publicité (non disponible dans ce dataset) pour statuer sur le **ROI**, au-delà de la seule significativité.

9. Dashboard Streamlit

L'application `app/streamlit_app.py` réunit les deux volets du projet dans une interface interactive unique, pensée comme une alternative à un rapport Power BI, mais versionnable en Python et exécutable en local sans licence.

9.1 Onglet Ventes

Requêtes SQL **en direct** sur DuckDB, filtrées dynamiquement par plage de dates, type de magasin, assortiment et statut promo. Affiche les KPIs (CA total, panier moyen, jours couverts, part de jours promo), la courbe de CA journalier filtrée, la saisonnalité hebdomadaire, l'effet promo et le CA par type de magasin

— équivalent interactif des figures 1, 2, 5 et 6.

9.2 Onglet Forecasting

Sélecteur de magasin (parmi les 3 profils étudiés), affichant les prévisions SARIMA et Prophet avec intervalles de confiance (à partir des prédictions exportées par le notebook 03, pour ne pas ré-entraîner les modèles à chaque clic), ainsi que le tableau comparatif RMSE/MAE/MAPE.

9.3 Onglet A/B Testing

Résultats du test A/B recalculés en direct depuis la table `marketing_ab` : taux de conversion par groupe avec IC, lift, p-values (chi² et z-test), et interprétation business rédigée dynamiquement.

9.4 Lancement

`streamlit run app/streamlit_app.py` — nécessite d'avoir exécuté au préalable les notebooks 01 à 04 pour générer les données traitées et les résultats.

10. Stack technique et structure du projet

Couche	Outils
Stockage / SQL	DuckDB
Traitement de données	pandas, numpy
Statistiques	scipy, statsmodels
Forecasting	statsmodels (SARIMAX), pmdarima (auto_arima), Prophet
Visualisation (notebooks)	matplotlib, seaborn
Dashboard	Streamlit, Plotly
Environnement	notebooks Jupyter exécutés via nbconvert, venv Python

10.1 Structure du dépôt

data/raw/, data/processed/ – données brutes et traitées
 sql/ – requêtes de contrôle qualité, KPIs, agrégations
 notebooks/ – 01_eda, 02_feature_engineering, 03_forecasting, 04_ab_testing
 src/ – chargement DuckDB
 app/ – dashboard Streamlit
 reports/ – figures générées par les notebooks
 docs/ – ce rapport

11. Limites et pistes d'amélioration

- **Comparaison SARIMA/Prophet non strictement équitable** : ajouter les mêmes régresseurs à un SARIMAX permettrait une comparaison à information égale (voir section 7.4).
- **Généralisation limitée** : le forecasting porte sur 3 magasins ; un passage à l'échelle sur les 1 115 magasins nécessiterait une approche batch (ex. un modèle global de type gradient boosting avec `store_id` en feature, plutôt que 1 115 modèles univariés).

- **Validation simple** : un seul split train/test a été utilisé ; une validation croisée « glissante » (walk-forward) donnerait une estimation plus robuste de l'erreur de généralisation.
- **A/B testing observationnel sur l'effet dose** : seul le contraste ad/psa est un vrai test randomisé ; l'analyse du nombre de publicités vues resterait à confirmer par un design expérimental dédié.
- **ROI non calculable** : le coût d'acquisition publicitaire n'est pas fourni dans le dataset, empêchant une recommandation business complète (le résultat est significatif, pas nécessairement rentable).
- **Dashboard non déployé publiquement** : actuellement exécuté en local ; un déploiement (Streamlit Community Cloud, Docker) faciliterait le partage en portfolio.

12. Conclusion

Ce projet démontre une chaîne complète d'analyse de données de bout en bout, de l'ingestion SQL à la restitution interactive, sur des données réelles et deux problématiques business distinctes. Le forecasting confirme que la valeur ajoutée d'un modèle ne tient pas qu'à sa sophistication algorithmique mais à sa capacité à intégrer la connaissance métier disponible (Prophet + régresseurs promo/vacances) ; l'A/B testing illustre l'importance de distinguer significativité statistique et ampleur/rentabilité business avant de recommander un déploiement. L'ensemble est reproductible (notebooks exécutés sans erreur, code versionné) et directement exploitable comme démonstrateur de compétences pour un portfolio data analytics / data science.

Annexe — Glossaire

RMSE	Root Mean Squared Error — racine de l'erreur quadratique moyenne. Pénalise fortement les grosses erreurs. Exprimée dans l'unité de la cible (ici, en euros de CA).
MAE	Mean Absolute Error — erreur absolue moyenne, en euros, plus facile à interpréter que le RMSE car moins sensible aux valeurs extrêmes.
MAPE	Mean Absolute Percentage Error — erreur relative moyenne en %, permet de comparer la précision entre magasins de tailles différentes.
Intervalle de confiance (IC) 95 %	Plage dans laquelle la vraie valeur a 95 % de chances de se trouver, compte tenu de l'incertitude du modèle ou de l'échantillon.
Test ADF (Augmented Dickey-Fuller)	Test statistique qui vérifie si une série temporelle est stationnaire (moyenne et variance stables dans le temps), condition nécessaire pour certains modèles comme ARIMA.
SARIMA	Seasonal AutoRegressive Integrated Moving Average — modèle statistique classique de série temporelle, capable de modéliser tendance, saisonnalité et autocorrélation.
Prophet	Modèle de forecasting open-source (Meta) décomposant une série en tendance + saisonnalités + effets de jours spéciaux/régresseurs, conçu pour être robuste aux séries business avec ruptures.
Test du χ^2 (khi-deux)	Test statistique vérifiant si deux variables catégorielles (ici : groupe A/B et conversion) sont indépendantes ou non.

Z-test de proportions	Test statistique comparant deux taux (proportions) entre eux, donnant en plus la direction et l'amplitude de l'écart.
p-value	Probabilité d'observer un résultat au moins aussi extrême que celui mesuré si l'hypothèse nulle (« pas d'effet ») était vraie. Un seuil de 5 % (0,05) est généralement utilisé pour conclure à un effet significatif.
Taille d'effet (Cohen's h)	Mesure de l'ampleur d'une différence entre deux proportions, indépendante de la taille de l'échantillon — à distinguer de la significativité statistique.
Puissance statistique	Probabilité de détecter un effet réel s'il existe. Dépend de la taille d'effet, de la taille d'échantillon et du seuil de significativité choisi.
Lag (retard)	Valeur de la série à une date antérieure (ex. j-7), utilisée comme variable explicative pour capturer l'autocorrélation.
Fuite de données (data leakage)	Erreur consistant à utiliser, lors de l'entraînement, une information qui ne serait pas disponible au moment réel de la prédiction — ici évitée en décalant les fenêtres mobiles d'un jour avant calcul.